

AI 동향 분석 보고서

세 가지 데이터로 읽는 2026년 AI 생태계

Ollama 라이브러리 · Arena 리더보드 · Epoch AI 주요 모델 DB
교차 분석 · 이상치 탐지 · 초보자 친화 해설

분석 데이터	엑셀 파일 3종 (모델 1,017 + 229 + 106건)
데이터 수집일	2026년 5월 20일 (UTC)
보고서 작성일	2026년 5월 21일
분석 범위	인기도 · 성능 · 기술 규모 교차

목차

목차.....	1
0. 한눈에 보기 (Executive Summary).....	1
1. 분석에 사용한 세 가지 데이터.....	1
1.1 세 데이터를 음식점에 빗대면.....	1
1.2 데이터 명세.....	1
2. 데이터별 정밀 분석과 이상치.....	1
2.1 Ollama 라이브러리 — 인기는 소수에 쏠려 있다.....	1
이상치 ① — llama3.1: ‘규칙을 깨는’ 다운로드 수.....	1
이상치 ② — nomic-embed-text: ‘보이지 않는 거인’.....	1
변곡점 ③ — ‘추론(thinking)’ 기능의 2025년 폭발.....	1
2.2 Arena 리더보드 — 분야마다 경쟁의 온도가 다르다.....	1
이상치 ④ — 분야별 점수 격차의 양극화.....	1
이상치 ⑤ — ‘들쭉날쭉한’ 모델: muse-spark의 수상한 점수.....	1
2.3 Epoch AI 주요 모델 — 폭주하는 ‘기술 군비 경쟁’.....	1
변곡점 ⑥ — 학습 연산량은 4~5개월마다 2배가 된다.....	1
이상치 ⑦ — Grok 4: ‘극단의 꼬리’.....	1
변곡점 ⑧ — 중국의 추격과 ‘오픈 vs 폐쇄’의 분기.....	1
3. 세 데이터를 잇는 교차 분석 3건.....	1
3.1 교차 분석 ① — ‘인기 모델이 곧 잘하는 모델인가?’ → 아니다.....	1
3.2 교차 분석 ② — ‘돈을 가장 많이 쓴 모델이 1등인가?’ → 아니다.....	1
3.3 교차 분석 ③ — ‘오픈 웨이트’가 세 데이터를 가르는 숨은 축.....	1
4. 이상치·변곡점 종합 정리.....	1
5. 그래서 무엇을 할 것인가 — 실행 인사이트.....	1
5.1 모델을 직접 골라 쓰는 개인·실무자에게.....	1
5.2 도입을 결정하는 기업·조직에게.....	1
5.3 큰 흐름을 읽으려는 관찰자에게.....	1
6. 분석 방법과 데이터 한계.....	1
6.1 분석 방법.....	1
6.2 데이터의 한계 — 해석 시 유의점.....	1

0. 한눈에 보기 (Executive Summary)

이 보고서는 서로 성격이 다른 세 개의 AI 데이터셋을 한자리에 놓고 비교한다. 각 데이터는 AI 생태계의 서로 다른 면을 비춘다. **Ollama 라이브러리**는 사람들이 ‘실제로 무엇을 내려받아 쓰는가’(인기도)를, **Arena 리더보드**는 ‘어떤 모델이 더 잘하는가’(성능)를, **Epoch AI 주요 모델 DB**는 ‘모델이 얼마나 크고 비싸게 만들어졌는가’(기술 규모와 역사)를 보여 준다.

세 데이터를 따로 보면 단순한 순위표에 그치지만, 서로 연결하면 ‘인기 있는 모델이 정말 잘하는 모델인가’, ‘돈을 가장 많이 쓴 모델이 1등인가’ 같은 질문에 답할 수 있다. 핵심 결론을 먼저 요약하면 다음과 같다.

이 보고서의 7가지 핵심 발견

- 1. 인기 ≠ 성능.** Ollama 1위 모델(llama3.1)은 성능 순위표에서 170위권에 그친다. 다운로드 수는 ‘오래된 정도’를 측정할 뿐이다.
- 2. 연산량 ≠ 1등.** 학습에 가장 많은 자원을 쓴 Grok 4는 Arena 최고 순위가 12위다. 1위는 그보다 훨씬 적은 자원으로 만든 Claude다.
- 3. 오픈 웨이트가 세 데이터를 잇는 ‘다리’다.** 내려받아 쓸 수 있는 모델만 Ollama에 오른다. 폐쇄형 1등 모델은 인기 데이터에서 사실상 보이지 않는다.
- 4. 쏠림이 극심하다.** Ollama 229개 모델 중 상위 10개가 전체 다운로드의 57.8%를 가져간다.
- 5. ‘추론(thinking)’ 기능이 2025년을 기점으로 폭발했다.** 탑재 비율이 0%→22%→69%로 급변했다.
- 6. 학습 연산량은 약 4~5개월마다 2배가 된다.** 반도체의 ‘무어의 법칙’(24개월)보다 5배 이상 빠른 속도다.
- 7. 중국이 ‘오픈’으로, 미국이 ‘폐쇄’로 갈라졌다.** 2024년 이후 중국 모델의 68%가 공개형, 미국은 21%에 그친다.

이어지는 본문은 (1) 세 데이터 소개, (2) 데이터별 정밀 분석과 이상치, (3) 세 데이터를 잇는 교차 분석 3건, (4) 변곡점·이상치 종합, (5) ‘그래서 무엇을 해야 하는가’ 실행 인사이트, (6) 분석 방법과 한계 순으로 전개된다. AI를 처음 접하는 독자도 이해할 수 있도록 전문 용어는 그때그때 풀어서 설명한다.

1. 분석에 사용한 세 가지 데이터

본격적인 분석에 앞서, 세 데이터가 각각 ‘무엇을’ 측정하는지 이해하는 것이 중요하다. 같은 ‘모델’이라는 단어를 쓰지만 측정하는 대상이 전혀 다르기 때문이다.

1.1 세 데이터를 음식점에 빗대면

이해를 돕기 위해 음식점에 비유해 보자. **Ollama 데이터**는 ‘어느 식당에 손님이 가장 많이 다녀갔는가’를 적은 **방문객 장부**다. **Arena 데이터**는 손님들이 두 음식을 직접 먹어 보고 더 맛있는 쪽에 투표한 **블라인드 맛 평가**다. **Epoch 데이터**는 ‘이 요리에 재료비와 조리 시간이 얼마나 들었는가’를 기록한 **주방 원가 대장**이다. 방문객이 많다고 맛이 1등은 아니고, 재료비를 많이 썼다고 맛이 보장되지 않는다 — 이 보고서의 출발점이 바로 이 어긋남이다.

1.2 데이터 명세

구분	Ollama 라이브러리	Arena 리더보드	Epoch AI 주요 모델
측정 대상	로컬 다운로드 인기도	대결 기반 성능 평가	학습 규모·기술 명세
수록 건수	모델 229개	순위 106행 / 세부 654개	모델 1,017개
기간	2023~2026 갱신	2026년 5월 시점	1950~2026년
대표 지표	Pulls(다운로드 수)	Arena Score(점수)	학습 연산량(FLOP)
핵심 질문	무엇을 쓰는가	무엇이 잘하는가	어떻게 만들었는가

용어 풀이 — 처음 보는 독자를 위해

Pulls(풀): Ollama에서 모델을 내려받은 누적 횟수. ‘조회수’와 비슷하며, 한 번 쌓이면 줄지 않는다.

Arena Score: 체스 실력 점수(Elo)와 같은 방식. 두 모델이 익명으로 대결해 사람이 더 나은 답을 고르고, 이긴 쪽 점수가 오른다. 1500점이면 1400점 모델을 상당히 앞선다는 뜻이다.

FLOP: 모델을 학습시키며 컴퓨터가 수행한 계산의 총량. 10의 25제곱($1e25$) 같은 어마어마한 숫자로 표시되며, 클수록 ‘더 많은 자원을 투입했다’는 의미다.

오픈 웨이트(공개 가중치): 모델의 ‘두뇌’에 해당하는 수치 파일을 누구나 내려받을 수 있게 공개한 것. 이 모델만 Ollama 같은 곳에서 직접 실행할 수 있다.

2. 데이터별 정밀 분석과 이상치

이 장에서는 세 데이터를 하나씩 깊이 들여다본다. 각 절의 마지막에는 ‘통계적으로 튀는 값’ — 즉 평균에서 크게 벗어난 이상치(outlier)나, 추세가 갑자기 꺾이는 변곡점 — 을 따로 짚는다.

2.1 Ollama 라이브러리 — 인기는 소수에 쏠려 있다

Ollama는 개인 PC나 회사 서버에서 AI 모델을 직접 돌릴 수 있게 해 주는 도구다. 데이터에는 229개 모델과 누적 다운로드 8억 9,075만 회가 담겨 있다. 가장 먼저 눈에 띄는 것은 **극심한 쏠림 현상**이다.




그림 1. Ollama 다운로드 상위 15개 모델과 누적 점유율 — 막대는 개별 다운로드 수, 빨간 선은 누적 비중

막대그래프의 ‘긴 꼬리’가 핵심이다. 1위 **llama3.1 한 모델이 전체의 12.9%**(1억 1,470만 회)를 차지하고, 상위 3개가 30.5%, 상위 5개가 42.5%, **상위 10개가 57.8%**를 가져간다. 반대로 다운로드가 적은 하위 절반(115개 모델)을 모두 합쳐도 전체의 7.2%에 불과하다. 즉 ‘소수의 스타 모델이 시장을 지배하고, 나머지 대다수는 거의 쓰이지 않는’ 승자 독식 구조다.

이런 쏠림은 통계적으로도 확인된다. 모델당 다운로드의 **중앙값은 98.96만 회**인데 **평균은 388.97만 회**로, 평균이 중앙값의 약 4배다. 평균이 중앙값보다 훨씬 크다는 것은 소수의 거대한 값이 평균을 끌어올린다는 ‘오른쪽으로 긴 꼬리’ 분포의 전형적 신호다.

이상치 ① — llama3.1: ‘규칙을 깨는’ 다운로드 수

통계에서 이상치는 흔히 ‘사분위 범위(IQR)’로 판정한다. 이 데이터에서 다운로드 수의 정상 범위 상한은 약 **394만 회**로 계산되며, 이를 넘는 모델이 30개 있다. 그중에서도 llama3.1(1억 1,470만)은 상한선의 **약 29배**에 달하는 압도적 이상치다. deepseek-r1(8,590만), nomiic-embed-text(7,080만), llama3.2(6,980만)가 그 뒤를 잇는다.

이상치 ② — nomic-embed-text: ‘보이지 않는 거인’

3위 nomic-embed-text는 성격이 전혀 다른 이상치다. 이것은 답변을 생성하는 챗봇이 아니라 **‘임베딩 모델’** — 문장을 컴퓨터가 검색·비교하기 쉬운 숫자로 바꿔 주는 부품 — 이다. Ollama의 임베딩 모델 12개를 합치면 **전체 다운로드의 11%(약 9,710만 회)**를 차지한다. 그런데 이들은 뒤에서 볼 Arena 성능 순위표에는 **단 하나도 등장하지 않는다**. 화려한 챗봇 뒤에서 검색·추천 기능을 조용히 떠받치는 ‘숨은 인프라’가 인기 데이터에만 잡히는 셈이다.

변곡점 ③ — ‘추론(thinking)’ 기능의 2025년 폭발

Ollama 데이터에는 각 모델이 갱신된 연도가 들어 있다. 이를 ‘추론 기능’ 탑재 여부와 교차하면 뚜렷한 변곡점이 보인다. ‘추론’이란 모델이 답을 곧장 내놓는 대신 **속으로 단계를 밟아 생각한 뒤** 답하는 방식으로, 어려운 수학·코딩 문제 정답률을 크게 끌어올린다.




그림 2. Ollama 모델의 ‘추론’ 기능 탑재 비율 — 2025년을 기점으로 급증

2023·2024년에 갱신된 모델 중 추론 기능을 가진 것은 **0%**였다. 그런데 2025년 22%, 2026년에는 **69%**로 치솟았다. 불과 1~2년 사이에 ‘추론’은 특수 기능에서 신형 모델의 **기본 사양**으로 자리 잡았다. 이는 단순한 점진적 변화가 아니라 업계 전체의 설계 방향이 한 번에 꺾인 ‘변곡점’이다.

그래서 뭐? — Ollama 데이터가 말해 주는 것

다운로드 1위라고 ‘가장 좋은 모델’이 아니다. 순위표 상단은 오래전 출시되어 다운로드를 오래 누적인 모델로 채워진다(상위 10개 중 다수가 2024년 갱신). 모델을 고를 때는 인기 순위가 아니라 ‘갱신 연도’와 ‘추론 기능 유무’를 함께 봐야 한다.

실무 권장: 로컬에서 쓸 모델을 고른다면 2025~2026년에 갱신된 deepseek-r1·qwen3·gemma3처럼 ‘인기도+최신성+추론 기능’을 모두 갖춘 모델이 합리적 선택이다.

2.2 Arena 리더보드 — 분야마다 경쟁의 온도가 다르다

Arena는 사람이 직접 두 모델의 답을 비교해 투표하는 방식의 평가다. 데이터에는 11개 분야(텍스트, 코딩, 이미지 생성, 영상 등)의 순위 106행과, 654개 모델의 세부 지표가 들어 있다. 분야별 1위는 다음과 같다.

분야	1위 모델	점수
Text (일반 대화)	claude-opus-4-6-thinking	1502
WebDev (웹 개발)	claude-opus-4-7-thinking	1567
Image-to-WebDev	claude-opus-4-7-thinking	1581
Vision (이미지 이해)	claude-opus-4-7-thinking	1306
Document (문서)	claude-opus-4-6-thinking	1522
Text-to-Image (이미지 생성)	gpt-image-2 (medium)	1393
Text-to-Video (영상 생성)	dreamina-seedance-2.0-720p	1457
Search (검색)	claude-opus-4-6-search	1251

언어·코딩·문서 등 ‘텍스트 기반’ 분야는 Claude 계열이, 이미지 생성은 OpenAI의 gpt-image-2가, 영상은 dreamina-seedance가 1위를 나눠 가졌다. **‘하나의 모델이 모든 것을 지배하지는 않는다’**는 점이 첫 번째 관찰이다.

이상치 ④ — 분야별 점수 격차의 양극화

더 흥미로운 것은 분야마다 ‘경쟁의 치열함’이 극과 극이라는 점이다. 1위와 꼴찌의 점수 차이를 비교해 보자.




그림 3. Arena 분야별 1위~꼴찌 점수 격차 — 빨강은 '독주', 초록은 '혼전'

일반 대화(Text) 분야는 1위와 10위의 차이가 **단 22점에** 불과하다. 1·2위 격차는 겨우 2점(claude-

opus-4-6-thinking 1502 대 4-7-thinking 1500)이다. 정상급 텍스트 모델들은 사실상 우열을 가리기 어려운 ‘평준화’ 구간에 들어섰다는 뜻이다.

반대로 이미지 생성(Text-to-Image)은 1위와 꼴찌의 차이가 **221점**으로 텍스트의 10배다. 특히 **1위와 2위의 격차만 125점**에 달한다. 이는 gpt-image-2가 이미지 생성에서 경쟁자를 압도하는 ‘독주 체제’임을 보여 준다. 영상 편집(175점)·이미지 편집(152점)도 비슷하게 격차가 크다.

이상치 ⑤ — ‘들쭉날쭉한’ 모델: muse-spark의 수상한 점수

세부 654개 모델 데이터에는 분야별(코딩·수학·창작 등) 등수가 함께 들어 있다. 종합 등수와 분야별 등수가 크게 어긋나는 모델이 이상치다. 대표 사례가 Meta의 **muse-spark**로, **종합 5위**인데 분야별 등수 평균은 16위, 등수 편차는 23에 이른다. gpt-5.4-high도 종합 10위지만 분야 편차가 26으로 크다. 이런 모델은 ‘특정 분야는 매우 잘하지만 다른 분야는 약한’ 불균형형이거나, 평가 표본이 적어 점수가 불안정한 경우다. **종합 순위만 보고 모델을 선택하면 약점 분야에서 실망할 수 있다**는 경고 신호다.

그래서 뭐? — Arena 데이터가 말해 주는 것

‘1등 모델’을 묻기 전에 ‘무슨 일에 쓸 건지’를 먼저 정하라. 일반 대화라면 상위 모델 어느 것을 써도 체감 차이가 작다(22점 차). 비용이 더 싼 2~5위 모델로 충분하다.

이미지·영상은 ‘1위를 반드시 써야 하는’ 분야다. 221점이라는 격차는 결과물 품질이 눈에 띄게 갈린다는 뜻이다. 이 분야에서는 1위 모델 사용이 비용을 정당화한다.

종합 순위와 분야 순위를 함께 확인하라. 편차가 큰 모델은 핵심 용도에서 직접 검증한 뒤 도입하는 것이 안전하다.

2.3 Epoch AI 주요 모델 — 폭주하는 ‘기술 군비 경쟁’

Epoch AI는 1950년대부터 현재까지 ‘주목할 만한’ AI 모델 1,017개를 정리한 데이터다. 학습 연산량, 파라미터(모델 크기), 제작 기관·국가, 공개 여부 등이 담겨 있어 AI 기술의 장기 추세를 볼 수 있다.

변곡점 ⑥ — 학습 연산량은 4~5개월마다 2배가 된다

가장 충격적인 수치는 학습 연산량의 증가 속도다. 연산량 추정치가 있는 524개 모델을 시간순으로 늘어놓으면 다음 그래프가 된다(세로축은 로그 척도 — 한 칸 올라갈 때마다 10배).




그림 4. 주요 AI 모델의 학습 연산량 추이 (2012~2026) — 빨간 추세선 기준 약 4.5개월마다 2배

2018년 이후 구간에서 학습 연산량은 연 약 **6.3배**, 즉 약 **4.5개월마다 2배**씩 늘었다. 2022년 이후만 보면 속도가 더 빨라져 약 4.1개월마다 2배다. 비교하자면, 반도체 성능이 2배가 되는 데 걸린다는 그 유명한 ‘무어의 법칙’ 주기가 약 24개월이다. **AI의 자원 투입 속도는 무어의 법칙보다 5배 이상 빠르다.**

연도별 중앙값을 보면 변곡점이 더 분명하다. 2023년 모델의 중앙 연산량은 약 6.3×10^{22} 였는데 **2024년에는 약 3.0×10^{24} 로 한 해 만에 약 48배** 뛰었다. ChatGPT 등장(2022년 말) 이후 업계가 일제히 ‘규모 키우기’에 뛰어든 결과로 읽힌다.

이상치 ⑦ — Grok 4: ‘극단의 꼬리’

연산량 분포의 오른쪽 끝은 극단적이다. 전체 중앙값은 약 8.7×10^{20} 인데, 최대값인 xAI의 **Grok 4는 약 5×10^{26}** — 중앙값의 약 **60만 배**다. 상위권은 Grok 4, GPT-4.5(3.8×10^{26}), Grok 3(3.5×10^{26}), GPT-5, Llama 4 Behemoth 순이다. 소수의 초거대 모델이 분포 전체를 끌고 가는, ‘긴 꼬리’의 교과서적 사례다.

순위	모델	기관	학습 연산량(FLOP)	공개 여부
1	Grok 4	xAI	5.0×10^{26}	비공개

순위	모델	기관	학습 연산량(FLOP)	공개 여부
2	GPT-4.5	OpenAI	3.8×10^{26}	비공개
3	Grok 3	xAI	3.5×10^{26}	비공개
4	GPT-5	OpenAI	6.6×10^{25}	비공개
5	Llama 4 Behemoth	Meta AI	5.2×10^{25}	비공개

변곡점 ⑧ — 중국의 추격과 ‘오픈 vs 폐쇄’의 분기

연산량 상위 50개 모델을 연도·국가별로 보면 또 하나의 변곡점이 나온다. 2023년에는 상위 50위권에 미국 모델이 7개, 중국이 0개였다. 그러나 2024년 미국 11 대 중국 5, **2025년에는 중국 12 대 미국 8로 역전됐다**. 최상위 ‘기술 군비 경쟁’에서 중국이 미국을 수적으로 따라잡은 것이다.

동시에 ‘모델을 공개하느냐’를 두고 두 나라가 갈라섰다. 전체적으로 공개(오픈 웨이트) 모델 비율은 2020년 56%에서 2026년 35%로 꾸준히 낮아졌다.




그림 5. (좌) 공개 모델 비율의 장기 하락 (우) 2024년 이후 국가별 공개 비율 — 중국 68% 대 미국 21%

그런데 2024년 이후만 떼어 보면 국가별 전략이 정반대다. **중국 모델은 68%가 공개형인 반면 미국 모델은 21%만 공개형**이다. 미국 선도 기업(OpenAI·Anthropic·xAI)은 모델을 ‘잠그는’ 쪽으로, 중국 기업(Alibaba·DeepSeek 등)은 ‘열어서 퍼뜨리는’ 쪽으로 움직였다. 이 분기는 다음 장의 교차 분석에서 결정적 역할을 한다.

그래서 뭐? — Epoch 데이터가 말해 주는 것

연산량 경쟁은 ‘지속 불가능한 속도’로 달리고 있다. 4~5개월마다 2배는 비용·전력 측면에서 오래 버틸 수 없다. 그래서 최근 모델들이 ‘같은 성능을 더 적은 연산으로’를 강조하기 시작했다(예: DeepSeek-V4는 추론 연산을 이전 세대의 27%로 줄였다고 발표).

자체 호스팅 전략은 ‘국가 리스크’를 고려해야 한다. 내려받아 쓸 수 있는 고성능 모델은 점점 중국발 비중이 커지고 있다. 보안·규제 환경에 따라 이는 기회이자 제약이 된다.

3. 세 데이터를 잇는 교차 분석 3건

지금까지는 데이터를 하나씩 봤다. 이 장이 보고서의 핵심이다. 세 데이터를 ‘연결’했을 때 비로소 드러나는 사실 3가지를 제시한다. 연결의 다리는 ‘모델 패밀리(계열)’다. 예컨대 llama3.1·llama3.2는 모두 ‘llama’ 계열로 묶어 세 데이터에서 같은 이름을 추적했다.




그림 6. 주요 모델 패밀리의 3대 데이터 내 위치 — 인기(좌)·성능(중)·역사적 비중(우)이 서로 다르게 나타난다

3.1 교차 분석 ① — ‘인기 모델이 곧 잘하는 모델인가?’ → 아니다

질문은 단순하다. Ollama에서 가장 많이 내려받는 모델이, Arena 성능 순위에서도 상위인가? 답은 **뚜렷한 ‘아니오’**다. 다음 표는 Ollama 다운로드 상위 모델과, 그 계열의 Arena 최고 순위를 나란히 놓은 것이다.

Ollama 인기 모델	다운로드	갱신연도	해당 계열 Arena 최고순위
llama3.1 (1위)	1억 1,470만	2024	170위
deepseek-r1 (2위)	8,590만	2025	30위
llama3.2 (4위)	6,980만	2024	170위
gemma3 (5위)	3,690만	2025	40위
qwen2.5 (6위)	3,060만	2024	14위

Ollama 1위 llama3.1이 속한 ‘llama’ 계열의 Arena 최고 순위는 **170위**에 그친다. 가장 많이 쓰이는 모델이 성능 순위표에서는 한참 아래에 있는 것이다. 이유는 두 가지다. 첫째, **다운로드는 누적 지표**라 일찍 나온 모델이 유리하다(llama3.1은 2024년 모델이다). 둘째, **성능 1등 모델은 대부분 폐쇄형이라 애초에 Ollama에 올라오지 못한다** — Arena 1위 Claude 계열의 Ollama 다운로드 는 ‘0’이다.

다만 예외가 있다. **deepseek-r1**은 Ollama 2위(8,590만 회)이면서 deepseek 계열 Arena 최고 30위로, ‘많이 쓰이면서 동시에 꽤 잘하는’ 드문 교집합에 든다. 2025년 모델이라 최신성도 갖췄다. 인기와 성능이 어긋나는 일반 법칙 속에서 deepseek-r1은 그 둘이 만나는 지점에 있다.

그래서 뭐?

Ollama 다운로드 순위를 ‘추천 순위’로 오해하지 말 것. 그것은 ‘오래되고 + 공개형’이라는 조건을

측정할 뿐 품질을 보장하지 않는다.

실전 선택 공식: '인기 상위권 n 2025년 이후 갱신 n 해당 계열 Arena 순위 양호' 세 조건을 모두 만족하는 모델을 골라라. 현재 데이터에서 그 답은 deepseek-r1, qwen3, gemma3다.

3.2 교차 분석 ② — ‘돈을 가장 많이 쓴 모델이 1등인가?’ → 아니다

두 번째 질문은 Epoch(연산량)과 Arena(성능)를 잇는다. 학습에 가장 많은 자원을 투입한 모델이 성능 1위인가?

모델 / 계열	학습 연산량(FLOP)	Arena 최고순위
Grok 4 / grok	5.0×10^{26} (전체 1위)	12위
GPT-4.5 계열 / gpt	3.8×10^{26} (전체 2위)	8위 (gpt-5.5-high)
Claude 3.7 Sonnet / claude	3.3×10^{25} (Grok 4의 약 1/15)	1위
Gemini 계열 / gemini	5.0×10^{25}	6위

결과는 명확하다. 학습 연산량 전체 1위인 **Grok 4의 Arena 최고 순위는 12위**다. 반면 Arena 종합 1위인 Claude 계열은, Epoch에 추정치가 있는 자사 모델(Claude 3.7 Sonnet, 약 3.3×10^{25}) 기준으로 **Grok 4보다 약 15배 적은 연산량**으로 만들어졌다. 즉 ‘가장 비싸게 만든 모델’과 ‘가장 잘하는 모델’은 일치하지 않는다.

이것이 의미하는 바는 크다. 한때 AI 업계의 믿음은 ‘연산량을 키우면 성능이 따라온다’는 단순한 공식이었다. 그러나 데이터는 정상권에서 그 공식이 ‘**수확 체감**’ 구간에 들어섰음을 보여 준다. 연산량을 2배 더 써도 Arena 점수는 그만큼 오르지 않는다. 대신 승부를 가르는 것은 **학습 후 다듬기(post-training), 추론 기능, 데이터 품질** 같은 ‘설계의 영리함’이다. 2.1절에서 본 ‘추론 기능의 폭발’과 이 발견은 같은 이야기의 양면이다 — 업계가 ‘무작정 키우기’에서 ‘똑똑하게 다듬기’로 무게중심을 옮긴 것이다.

그래서 뭐?

모델 도입 시 ‘파라미터 수·연산량’ 같은 스펙 숫자에 휘둘리지 말 것. 그 숫자는 비용을 알려 줄 뿐 실제 품질 순위와 어긋난다. 판단 기준은 언제나 Arena 같은 ‘실사용 평가’여야 한다.

업계 방향성 신호: 효율(적은 연산으로 같은 성능)이 새로운 경쟁축이다. DeepSeek-V4의 ‘추론 연산 27% 감축’ 발표가 그 증거이며, 이는 향후 AI 사용 비용이 낮아질 수 있다는 긍정적 전망으로 읽힌다.

3.3 교차 분석 ③ — ‘오픈 웨이트’가 세 데이터를 가르는 숨은 축

앞의 두 분석에서 반복해 등장한 단서가 있다. ‘Claude는 Ollama에 0건’, ‘성능 1위는 폐쇄형’. 세 번째 교차 분석은 이 단서를 정면으로 다룬다. 결론부터 말하면, **‘모델을 공개했는가(오픈 웨이트)’가 세 데이터에서 모델의 위치를 결정하는 숨은 축**이다.

논리는 이렇다. Ollama는 본질적으로 ‘내려받아 직접 실행하는’ 도구이므로, **공개형 모델만 Ollama에 존재할 수 있다**. 따라서 폐쇄형인 Claude·Grok·GPT(대부분)·Gemini는 Arena 성능 최상위권을 차지하면서도 Ollama에서는 사실상 보이지 않는다. 다음 표가 이 단절을 보여 준다.

계열	Ollama 모델수 / 다운로드	Arena 최고순위	공개 여부	세 데이터 모두 등장?
qwen	15개 / 1억 1,845만	14위	공개	O
deepseek	12개 / 1억 205만	30위	공개	O
gemma	12개 / 8,528만	40위	공개	O
claude	0개 / 0	1위	비공개	X (Ollama 없음)
grok	0개 / 0	12위	비공개	X (Ollama 없음)
gpt	2개 / 984만	8위	대부분 비공개	△ (소량만)

표에서 가장 중요한 줄은 **qwen(알리바바)**이다. qwen은 Ollama에서 15개 모델·1억 1,845만 다운로드(인기), Arena 최고 14위(성능), Epoch 등재 35건(역사적 비중)으로 **세 데이터 모두에서 동시에 강한 거의 유일한 계열**이다. 비결은 단순하다. 알리바바가 최상위급 성능의 모델을 ‘공개형으로’ 내놓기 때문이다. 성능과 공개성을 모두 가졌기에 세 데이터를 가로지를 수 있다.

여기서 2.3절의 발견과 연결된다. 2024년 이후 **중국 모델의 68%가 공개형, 미국은 21%**였다. 바로 이 국가별 전략 차이가, Ollama 인기 상위권이 qwen·deepseek·gemma 같은 계열(중국계 + 구글의 공개형 gemma)로 채워지는 **근본 원인**이다. 미국 선도 기업이 모델을 ‘잠그는’ 동안, 중국 기업과 일부 공개 진영이 ‘로컬에서 쓸 수 있는 모델’ 시장을 빠르게 채운 것이다.

그래서 뭐?

자체 호스팅(privacy·비용·오프라인)이 필요하면 선택지는 사실상 정해져 있다. qwen, deepseek, gemma 같은 공개형 계열이다. 폐쇄형 미국 프런티어 모델은 이 용도에 쓸 수 없다.

전략적 시사점: 자체 호스팅용 고성능 모델 시장은 중국계 비중이 빠르게 커지고 있다. 조직의 보안·규제·공급망 정책에 따라 ‘오픈 웨이트 의존도’를 의식적으로 관리할 필요가 있다.

‘공개 여부’를 모델 선택의 1차 분류 기준으로 삼아라. API로 부르면 그만이면 폐쇄형 최상위 모델을, 데이터를 외부로 보낼 수 없으면 공개형 상위 모델을 — 이 갈림길이 다른 모든 선택에 앞선다.

4. 이상치·변곡점 종합 정리

2~3장에서 짚은 ‘통계적으로 튀는 값’을 한 표에 모았다. 이상치(평균에서 크게 벗어난 값)와 변곡점(추세가 꺾이는 지점)은 데이터에서 ‘이야기가 숨어 있는 자리’다.

데이터	튀는 값 / 변곡점	수치	의미
Ollama	llama3.1 다운로드 이상치	정상 상한의 약 29배	소수 스타 모델의 독식
Ollama	임베딩 모델의 숨은 비중	전체 다운로드의 11%	Arena엔 0건, 인기 데이터만 포착
Ollama	‘추론’ 기능 탑재율 변곡점	0%→22%→69%	2025년 설계 패러다임 전환
Arena	분야별 점수격차 양극화	Text 22점 / 이미지 221점	분야마다 경쟁 강도 극과 극
Arena	muse-spark 등수 불일치	종합5위 vs 분야평균16위	종합점수만 보면 위험
Epoch	연산량 증가 변곡점	약 4.5개월마다 2배	무어의 법칙의 5배 속도
Epoch	2023→2024 중앙 연산량 급등	약 48배	ChatGPT 이후 규모 경쟁 점화
Epoch	Grok 4 연산량 극단치	중앙값의 약 60만 배	초거대 모델의 긴 꼬리
Epoch	상위50 연산량 국가 역전	2025년 중국12 vs 미국8	중국의 프런티어 추격

이 표를 관통하는 하나의 주제는 ‘**AI 생태계는 평균이 아니라 극단으로 움직인다**’는 것이다. 다운로드도, 연산량도, 분야별 격차도 모두 소수의 거대한 값이 전체를 좌우한다. 따라서 ‘평균적인 모델’을 상상하며 의사결정을 하면 현실과 어긋난다. 늘 ‘상위 몇 개가 무엇인가’, ‘추세가 어디서 꺾였는가’를 먼저 물어야 한다.

5. 그래서 무엇을 할 것인가 — 실행 인사이트

보고서의 마지막 장은 ‘분석’이 아니라 ‘행동’에 관한 것이다. 독자의 입장(개인 사용자, 기업 의사결정자, AI 관찰자)별로 데이터가 원하는 바를 정리한다.

5.1 모델을 직접 골라 쓰는 개인·실무자에게

1. **인기 순위가 아니라 ‘최신성 + 추론 기능 + 성능’으로 고르라.** Ollama 다운로드 1위는 ‘오래된 공개형’일 뿐이다. 2025~2026년 갱신, 추론 기능 탑재, 해당 계열 Arena 순위 양호 — 이 세 조건을 만족하는 deepseek-r1·qwen3·gemma3가 현 시점의 합리적 출발점이다.
2. **용도부터 정하라.** 일반 대화·요약이라면 최상위와 2~5위의 체감 차이가 작으니(22점) 더 저렴한 모델로 충분하다. 반면 이미지·영상 생성은 1위와 2위 격차가 100점을 넘으므로 1위 모델 사용이 비용을 정당화한다.
3. **‘API로 부를 것인가, 직접 돌릴 것인가’를 먼저 결정하라.** 데이터를 외부로 보내도 되면 폐쇄형 최상위 모델(Claude·GPT·Gemini)을, 보안·비용·오프라인 때문에 직접 돌려야 하면 공개형(qwen·deepseek·gemma)을 본다. 이 갈림길이 다른 모든 선택에 앞선다.

5.2 도입을 결정하는 기업·조직에게

4. **스펙 숫자가 아니라 실사용 평가로 검증하라.** 연산량·파라미터 수가 큰 모델이 더 나은 것은 아니다 (Grok 4 = 연산량 1위, 성능 12위). 도입 전 자사 핵심 업무로 직접 비교 테스트를 거쳐야 한다. 종합 순위가 높아도 분야 편차가 큰 모델(muse-spark형)은 특히 주의한다.
5. **‘오픈 웨이트 의존도’를 전략 변수로 관리하라.** 자체 호스팅용 고성능 공개 모델 시장은 중국계 비중이 커지고 있다. 보안·규제·공급망 관점에서 어떤 계열에 의존할지를 의식적으로 결정하고 문서화하라.
6. **비용 하락에 베팅하되 서두르지 마라.** 연산량 4~5개월 배증은 지속 불가능하며, 업계는 ‘효율’로 방향을 틀고 있다(DeepSeek-V4의 추론 연산 27%). 향후 동급 성능의 사용 비용이 내려갈 가능성이 크므로, 장기 고정 계약보다 유연한 도입 구조가 유리하다.

5.3 큰 흐름을 읽으려는 관찰자에게

- **패러다임 전환:** ‘무작정 키우기’의 시대가 정점을 지나, ‘추론·효율로 다듬기’의 시대로 넘어가는 변곡점에 와 있다. 추론 기능 탑재율 0→69%가 그 증거다.
- **지정학적 분기:** AI는 ‘미국=폐쇄·프런티어’ 대 ‘중국=공개·확산’이라는 두 갈래로 갈라지고 있다. 공개 생태계(Ollama)의 주도권을 누가 쥐느냐가 향후 핵심 쟁점이다.
- **측정의 함정:** ‘인기’, ‘연산량’, ‘성능’은 서로 다른 것을 측정한다. 하나의 숫자로 AI를 줄 세우려는 시도는 거의 항상 오해를 부른다 — 이것이 이 보고서 전체의 메타 교훈이다.

한 문장 요약

‘무엇이 인기인가’, ‘무엇이 잘하는가’, ‘무엇에 돈을 썼는가’는 서로 다른 질문이며, 세 답이 어긋나는 그 틈에 2026년 AI 생태계의 진짜 이야기가 있다.

6. 분석 방법과 데이터 한계

6.1 분석 방법

세 파일은 Python(pandas)으로 처리했다. 이상치는 사분위 범위(IQR) 방식 — 제3사분위수 + $1.5 \times \text{IQR}$ 을 상한으로 — 으로 판정했다. 연산량 증가율은 발행일과 학습 연산량(로그 변환)에 대한 선형 회귀로 추정했다. 교차 분석은 모델 이름에서 '계열(family)' 키워드(llama, qwen, claude 등)를 추출해 세 데이터를 연결했다.

6.2 데이터의 한계 — 해석 시 유의점

- **다운로드 수는 누적값이다.** 오래된 모델이 구조적으로 유리하므로 '현재 인기'와 다를 수 있다.
- **Arena 점수는 사람 투표 기반이다.** 표본이 적은 신규·특수 모델은 점수가 불안정할 수 있다(muse-spark 사례).
- **Epoch 연산량은 추정치다.** 기업이 공식 수치를 공개하지 않는 경우가 많아 오차가 있을 수 있고, 1,017개 중 524개만 연산량 값이 있다.
- **'주목할 만한 모델'은 선별된 목록이다.** 최근 연도는 아직 집계 중이라 모델 수가 실제보다 적게 보일 수 있다(2024년 수치가 2023년보다 낮은 것도 이 때문일 가능성).
- **계열 키워드 매칭은 근사다.** 이름이 다른 같은 계열, 또는 우연히 키워드가 겹치는 경우가 일부 포함될 수 있다.
- **데이터 수집 시점은 2026년 5월 20일이다.** 이후 출시·갱신된 모델은 반영되지 않았다.

출처: Ollama 라이브러리(ollama.com/library), Arena 리더보드(arena.ai/leaderboard), Epoch AI 주요 AI 모델 데이터베이스. 본 보고서의 모든 수치는 위 세 파일(2026-05-20 수집분)에서 직접 산출한 것이다.