

AI 동향 분석 보고서

Ollama Library, Arena Leaderboard, Epoch Notable AI Models 교차 분석

핵심 결론

인기, 성능, 산업 투자는 같은 지표가 아니다. Ollama는 로컬 실사용, Arena는 현재 성능/선호도, Epoch는 산업 투자 흐름을 보여준다. 세 데이터를 함께 볼 때 모델 선택 전략이 선명해진다.

항목	값
분석 기준	2026-05-21 02:34 KST 수집본
Ollama Library	229개 모델 / 누적 pull 8.91억
Arena Leaderboard	Compact View 654개 모델 / 11개 카테고리
Epoch Notable AI Models	1,017개 모델 / 1950-07-02~2026-04-24

1. Executive Summary

- Ollama 상위 20개 모델이 전체 pull의 70.2%를 차지해 로컬 생태계가 소수 핵심 모델에 강하게 집중되어 있다.
- Arena에서는 Claude, GPT, Gemini 등 폐쇄형 프런티어 모델이 상위권을 주도하지만, Ollama에서는 Llama, Qwen, DeepSeek, Gemma 계열이 실사용을 만든다.
- Qwen과 DeepSeek은 로컬 실사용과 Arena 성능 신호가 동시에 나타나는 중간 지대 모델 계열이다.
- 텍스트/비전 모델은 성능 격차가 줄고 있지만 이미지·비디오 생성/편집 영역은 1위와 2위 격차가 크다.
- Epoch 기준 훈련 계산량은 극단적으로 치우쳐 있으며, 최대값은 중간값의 약 57만 배 수준이다.




그림 1. Ollama 상위 모델 pull 집중도와 누적 점유율

2. 데이터 읽는 법

데이터	무엇을 의미하나	주의할 점
Ollama pull	모델이 얼마나 많이 내려받아졌는지 보여주는 실사용/생태계 신호	누적 지표라 오래된 모델이 유리할 수 있음
Arena rank/score	사용자 선호 또는 평가에서 현재 강한 모델을 보여주는 성능 신호	카테고리별 평가 방식에 영향을 받음
Epoch FLOP	모델 훈련에 들어간 계산량과 산업 투자 규모를 보여주는 신호	기록이 없는 모델도 많고 전체 시장을 완전히 대표하지는 않음
Open weights	모델 가중치를 공개해 직접 운영할 수 있는지 여부	공개 여부와 사용 편의성은 별도 평가가 필요

3. 세 데이터를 연결한 교차 분석

3.1 Ollama 인기 모델이 Arena에서도 상위인가?

부분적으로만 맞다. Llama는 Ollama에서 약 2.51억 pull로 압도적이지만 Arena 최고 Overall 순위는 170위권이다. 반면 Qwen은 약 1.18억 pull과 Arena 최고 14위, DeepSeek은 약 1.02억 pull과 Arena 최고 30위를 보여 실사용과 성능 신호가 함께 나타난다.

성능 1위만 보면 실제 배포 가능성과 생태계를 놓친다. 제품 개발자는 모델 성능뿐 아니라 로컬 실행 가능성, 문서/예제, 변형 모델 수, 운영 비용까지 함께 봐야 한다.

3.2 오픈/로컬 생태계와 폐쇄형 프런티어 모델의 분화

Arena 상위권은 Anthropic, OpenAI, Google, xAI 같은 대형 연구소 모델이 주도한다. 반면 Ollama 상위권은 Llama, Qwen, DeepSeek, Gemma, Mistral처럼 로컬 실행 또는 오픈 생태계와 가까운 계열이 중심이다.

그래서 뭐?

기업의 현실적인 선택은 단일 모델이 아니라 하이브리드 라우팅이다. 쉬운 반복 작업은 로컬/오픈 모델로, 고난도 추론과 고품질 생성은 프런티어 API로 보내는 구조가 비용과 품질을 동시에 잡는다.

3.3 어느 분야가 성숙했고, 어디가 아직 요동치는가?

Arena에서 Text와 Vision의 1위-2위 점수 차는 각각 2점뿐이다. 반면 Text-to-Image는 125점, Image Edit는 74점, Video Edit는 60점 차이가 난다. 오래 투자된 텍스트/비전 영역은 상향 평준화되고, 생성형 미디어는 아직 선두 모델의 영향이 크다.

그래서 뭐?

챗봇만으로 차별화하기는 어려워진다. 앞으로 사용자 경험의 차이는 이미지/비디오, 문서 처리, 검색 결합, 도구 사용, 에이전트형 작업에서 더 크게 벌어진다.

주요 모델 계열 교차 비교

Ollama 실사용, Arena 성능, Epoch 기록 수를 같은 행에서 비교

계열	Ollama pull	Arena 최고 순위	Epoch 기록 수
llama	2.51억	#170	20개
qwen	1.18억	#14	35개
deepseek	1.02억	#30	9개
gemma	8528.1만	#40	1개
mistral	4677.2만	#93	6개
gpt	984.1만	#8	51개
claude	0	#1	14개
gemini	190만	#6	23개
grok	0	#12	8개
glm	1091만	#20	11개

읽는 법: Arena 순위는 숫자가 낮을수록 좋으므로, 막대는 좋은 순위일수록 길게 표시했습니다.

그림 2. 주요 모델 계열의 Ollama, Arena, Epoch 신호 비교

4. 데이터별 이상치와 패턴 변화

4.1 Ollama: 소수 모델로 사용량 집중

지표	값	해석
총 pull	8.91억	로컬 모델 실사용 규모가 크다
중간값	99만	대부분 모델은 100만 pull 전후
평균	389만	상위 모델이 평균을 크게 끌어올림
상위 20개 비중	70.2%	소수 핵심 모델에 사용량 집중
IQR 기준 pull 이상치	30개	상위 모델군이 뚜렷하게 분리됨




그림 3. Ollama 신규/갱신 모델 중 thinking 기능 탑재 비율

4.2 Arena: 텍스트는 혼전, 생성형 미디어는 독주

텍스트와 비전 카테고리의 선두 격차는 작지만, 이미지/비디오 생성 및 편집에서는 1위 모델과 추격 모델의 격차가 크다. 이는 분야별 성숙도가 다르다는 뜻이다.




그림 4. Arena 카테고리별 점수 격차

4.3 Epoch: 계산량은 몇 자릿수 단위로 벌어진다

Epoch에서 훈련 계산량이 있는 모델은 524개다. 중간값은 $8.68e+20$ FLOP, 최대값은 $5.00e+26$ FLOP로, 프런티어 모델의 계산 자원 투입이 일반 모델과 극단적으로 벌어져 있다.




그림 5. 주요 AI 모델의 훈련 연산량 증가 추이




그림 6. 공개 가중치 모델 비율 변화

5. 실무 인사이트와 추천 행동

상황	우선 볼 지표	추천 방향
민감 정보·내부 자동화	Ollama pull, 태그 수, 공개 가중치	로컬/오픈 모델 우선 검토
고품질 생성·복잡한 추론	Arena 상위 순위와 작업별 점수	프런티어 API 우선 검토
RAG·검색·문서 연결	임베딩 모델 pull과 생태계	임베딩 모델을 대화 모델과 별도 평가
이미지·비디오 생성	Arena 카테고리별 1위 격차	카테고리별 선두 모델을 직접 테스트
비용 최적화	성능 격차가 작은 카테고리	작업 난이도별 모델 라우팅

5.1 사용자/개인 개발자

- 로컬 실행은 Llama, Qwen, DeepSeek, Gemma 계열부터 비교한다.
- 검색형 AI나 RAG를 만들 때는 nomic-embed-text, mxbai-embed-large 같은 임베딩 모델을 별도로 평가한다.
- 이미지/비디오 작업은 Arena 카테고리별 1위 모델을 먼저 테스트한다.

5.2 제품/서비스 팀

- 단일 모델 전략보다 모델 라우팅 전략을 세운다.
- 쉬운 요청은 로컬/오픈 모델, 어려운 요청은 프런티어 API로 보내는 구조를 검토한다.
- 텍스트 모델은 성능 차가 줄어드므로 가격, latency, 안정성, 도구 연동을 함께 본다.

5.3 리서치/전략 팀

- Qwen, DeepSeek, GLM, Kimi처럼 오픈 생태계와 Arena 성능 양쪽에 걸친 계열을 추적한다.
- Epoch의 compute 상위 모델과 Arena 순위 변화를 함께 보며 계산량 증가가 실제 선호로 이어지는지 확인한다.
- Ollama tag 수와 pull 증가를 함께 보면 커뮤니티 채택의 초기 신호를 포착할 수 있다.

6. 한계와 주의사항

- Ollama pull은 누적 지표라 오래된 모델이 유리하다.
- Arena 점수는 카테고리별 평가 방식과 시점에 영향을 받는다.
- Epoch는 notable 모델 데이터이므로 전체 시장의 완전한 목록은 아니다.
- 모델 계열 매칭은 이름 기반이므로 세부 버전이 완전히 동일하다는 뜻은 아니다.